

# **Análisis Transporte Madrid 2022**

*Andrés Nó Gómez*

## Contents

|          |                                                         |           |
|----------|---------------------------------------------------------|-----------|
| <b>1</b> | <b>Introducción y fuentes</b>                           | <b>2</b>  |
| <b>2</b> | <b>Análisis Exploratorio de Datos (EDA)</b>             | <b>2</b>  |
| 2.1      | EDA BiciMadrid . . . . .                                | 3         |
| 2.2      | EDA Tráfico . . . . .                                   | 4         |
| 2.3      | EDA Datos Meteorológicos . . . . .                      | 5         |
| 2.4      | EDA Datos Calendario Laboral . . . . .                  | 6         |
| <b>3</b> | <b>Integración y Análisis Conjunto</b>                  | <b>6</b>  |
| 3.1      | Agregación de Datos . . . . .                           | 7         |
| 3.2      | Análisis de Correlaciones . . . . .                     | 7         |
| <b>4</b> | <b>Modelo de datos y creación de métricas en PoweBI</b> | <b>8</b>  |
| <b>5</b> | <b>Resultados e Insights Globales</b>                   | <b>10</b> |
| 5.1      | Magnitudes generales del sistema . . . . .              | 10        |
| 5.2      | Análisis temporal . . . . .                             | 10        |
| 5.3      | Impacto del tipo de día . . . . .                       | 11        |
| 5.4      | Influencia meteorológica . . . . .                      | 12        |
| 5.5      | Insights de interacción . . . . .                       | 12        |
| <b>6</b> | <b>Conclusiones</b>                                     | <b>13</b> |
| 6.1      | Logros metodológicos . . . . .                          | 13        |
| 6.2      | Hallazgos principales . . . . .                         | 13        |
| 6.3      | Implicaciones para políticas de movilidad . . . . .     | 14        |
| 6.4      | Limitaciones y trabajo futuro . . . . .                 | 14        |

## 1 Introducción y fuentes

Este proyecto analiza cómo las condiciones meteorológicas y el calendario laboral afectan la movilidad urbana en Madrid durante 2022, específicamente el uso del sistema BiciMad y el tráfico vehicular.

El objetivo es generar insights para políticas de movilidad sostenible mediante el análisis de patrones de transporte en función de factores externos como clima y tipo de día.

Se utilizaron cuatro fuentes oficiales de datos de 2022:

**BiciMad:** Registros de viajes del sistema de bicicletas públicas (EMT Madrid). Más de 4 millones de trayectos con información de fechas, horas, duración y estaciones.

*Fuente*

**Tráfico:** Mediciones por horad de intensidad vehicular de 60 estaciones de aforamiento permanente (Ayuntamiento de Madrid).

*Fuente*

**Meteorología:** Datos climáticos diarios incluyendo temperatura, precipitación, viento y presión (Meteostat API).

*Fuente*

**Calendario laboral:** Clasificación oficial de días laborables, festivos y fines de semana (Ayuntamiento de Madrid).

*Fuente*

La metodología incluye tres fases: análisis exploratorio individual de cada dataset, integración en un dataset unificado para un análisis pre-eliminar conjunto en el que comprobamos la coherencia entre datasets y modelado en Power BI para visualización interactiva.

## 2 Análisis Exploratorio de Datos (EDA)

El análisis exploratorio de datos constituye la fase fundamental para comprender la estructura, calidad y características de cada dataset antes de su integración. Los objetivos principales de esta etapa son: identificar y corregir problemas de calidad de datos (valores faltantes, duplicados, anomalías), estandarizar formatos y nomenclaturas para facilitar la posterior integración, y extraer insights preliminares sobre patrones y distribuciones en cada fuente de datos.

Cada dataset presentó desafíos específicos que requirieron soluciones adaptadas. Los análisis detallados, incluyendo exploraciones técnicas exhaustivas y visualizaciones adicionales, se encuen-

tran documentados en las notebooks individuales de cada EDA. En este informe se presentan únicamente los aspectos más relevantes y las decisiones clave tomadas durante el proceso.

## 2.1 EDA BiciMadrid

El dataset de BiciMadrid consistía en 12 archivos CSV mensuales con más de 8.3 millones de registros iniciales, representando todos los viajes del sistema de bicicletas públicas durante 2022.

### Problemas identificados y soluciones:

- *Inconsistencia estructural*: Los archivos mensuales presentaban diferencias en el número de columnas debido a la presencia irregular de la columna 'idTrip'. Se eliminó esta columna por no aportar valor analítico, permitiendo la concatenación uniforme de todos los archivos.
- *Filas vacías intercaladas*: Se detectaron 4.1 millones de filas completamente vacías distribuidas aleatoriamente en el dataset, resultado de errores en la generación de los archivos fuente. Todas fueron eliminadas automáticamente.
- *Nomenclatura inconsistente de estaciones*: El mismo punto físico aparecía con múltiples nombres (ej: "96 - Cibeles" vs "Cibeles", "Plaza España A" vs "Plaza España B"), creando artificialmente estaciones duplicadas. Se unificó la nomenclatura eliminando prefijos numéricos y sufijos A/B, consolidando de 400+ nombres a 258 estaciones reales.
- *Registros duplicados*: 140,000 viajes (3.4%) estaban duplicados completamente. Se eliminaron conservando una única instancia de cada viaje.
- *Anomalías en duración*: Se identificaron 16,256 registros con duraciones imposibles (valores negativos hasta -8,677 minutos y viajes de hasta 696 horas). Estas anomalías se corrigieron mediante sustitución por la media de valores válidos.
- *Valores faltantes*: Los nombres de estaciones presentaban 0.5% de valores faltantes, que se categorizaron como "Unknown" para preservar la información de los viajes.

**Dataset final:** 4.07 millones de viajes válidos con 5 variables esenciales: duración, estaciones de origen/destino, fecha y hora.

### 2.1.1 Insights BiciMadrid

El análisis reveló patrones típicos de movilidad urbana: duración media de viajes de 12.1 minutos, concentración en trayectos de 5-15 minutos, y distribución equilibrada del uso entre esta-

ciones (el top 10% concentra solo el 20% de los viajes). Estos patrones confirman que BiciMadrid funciona principalmente como complemento al transporte público para conexiones cortas.

## 2.2 EDA Tráfico

El dataset de tráfico integra 12 archivos Excel con mediciones de 60 estaciones permanentes en formato horario.

### Problemas identificados y soluciones:

- *Estructura poco analítica*: Los datos venían en formato horizontal (bloques horarios y sentidos). Presentaban una estructura de 4 filas por día y estación (2 sentidos  $\times$  2 bloques horarios) con columnas HOR1-HOR12 representando franjas de 2 horas cada una. El campo FSEN codificaba simultáneamente sentido del tráfico y bloque horario ("1-" = Sentido 1 horas 1:00-12:00, "1=" = Sentido 1 horas 13:00-24:00, etc.). **Solución**: Aplicación de operación melt para convertir columnas HOR1-HOR12 en filas, seguida de mapeo temporal complejo donde se extrajo el índice numérico del slot y se calculó la hora final según FSEN (para "-" usar directamente 1-12, para "=" sumar 12 resultando en 13-24), normalizando hora 24 a 0 para mantener rango estándar 0-23.
- *Codificación horaria en dos bloques*: La separación en dos mitades del día complicaba el análisis. Se normalizó a horas 0-23 para facilitar cruces con otros datasets.
- *Cobertura incompleta*: Faltan 11 días consecutivos de diciembre. Se documenta la limitación y el análisis diario se realiza sobre 354 días válidos.
- *Valores muy altos*: Aparecen picos cercanos a 9 000-10 000 veh/h en varias franjas. No se interpretan como errores ni "códigos", sino como posibles techos de sensor. Se conservaron tal cual para respetar el registro original; su presencia es poco frecuente y no altera las conclusiones generales.

**Dataset final**: 467 280 filas reestructuradas con 4 variables: día, hora, estación y afluencia (agregada por sentidos).

### 2.2.1 Insights Tráfico

Patrones horarios realistas con colas derechas (picos en vías principales). Los valores cercanos a 10 000 veh/h son coherentes con límites de medición; la gran mayoría de observaciones queda muy por debajo, por lo que los extremos no distorsionan el conjunto.

## 2.3 EDA Datos Meteorológicos

El dataset meteorológico se obtuvo mediante la API de Meteostat, proporcionando datos diarios para Madrid durante todo 2022 con variables climáticas estándar.

### Problemas identificados y soluciones:

- *Descarga directa desde API*: Los datos se obtuvieron automáticamente mediante la API de Meteostat usando las coordenadas de la Puerta del Sol (40.4169, -3.7033) como referencia. La estructura venía predefinida y normalizada desde el origen, evitando problemas de formato típicos de archivos manuales.
- *Variables irrelevantes*: La descarga incluía 10 variables originalmente (`tavg`, `tmin`, `tmax`, `prcp`, `snow`, `wdir`, `wspd`, `wpgt`, `pres`, `tsun`), muchas con valores faltantes extensos. Se mantuvieron únicamente las 4 variables completas y relevantes: temperatura media (`tavg`), mínima (`tmin`), máxima (`tmax`) y precipitación (`prcp`).
- *Cobertura temporal perfecta*: El dataset cubría exactamente los 365 días de 2022 sin lagunas temporales, a diferencia de otros datasets del proyecto que presentaban días faltantes.
- *Ausencia de anomalías*: No se detectaron valores duplicados, faltantes ni anomalías en las variables seleccionadas. Los valores extremos en precipitación (hasta 26.6 mm) y temperatura (-0.5°C mínima, 40.7°C máxima) son climatológicamente coherentes para Madrid.
- *Categorización para análisis*: Se crearon variables categóricas mediante cuartiles para temperatura (Fría/Fresca/Templada/Calurosa) y separación especial para precipitación (Sin lluvia/Lluvia ligera/Lluvia intensa) para facilitar análisis posteriores de impacto en movilidad.

**Dataset final:** 365 registros diarios con 7 variables: fecha, 4 numéricas climáticas y 2 categóricas derivadas.

### 2.3.1 Insights Meteorológicos

Madrid 2022 registró temperatura media anual de 16.50°C (rango: 3.40°C a 33.70°C) con marcada estacionalidad. La precipitación fue escasa: media de 1.33 mm/día, y se halló que hubo cerca de 300 días del año sin lluvia (0 mm). El máximo de precipitación fue 26.60 mm. Los datos reflejan el clima mediterráneo continental típico, proporcionando suficiente variabilidad para analizar impactos en patrones de movilidad urbana.

## 2.4 EDA Datos Calendario Laboral

El dataset de calendario laboral se obtuvo del Portal de datos abiertos del Ayuntamiento de Madrid, conteniendo la clasificación oficial de días para múltiples años (2013-2024).

### Problemas identificados y soluciones:

- *Cobertura temporal excesiva*: El dataset original contenía 4 747 registros abarcando múltiples años (2013-2024), cuando solo necesitábamos 2022. Se aplicó filtro específico por año resultando en exactamente 365 días de 2022.
- *Columnas irrelevantes*: El archivo incluía columnas **Tipo de Festivo** y **Festividad** con información detallada sobre celebraciones que no es relevante para el análisis de movilidad. Se eliminaron conservando solo las variables esenciales.
- *Codificación de caracteres*: La primera columna presentaba caracteres de codificación (ï»¿Dia). Se renombró correctamente a **Dia** para evitar errores posteriores.
- *Datos incompletos en columna Tipo*: Tras filtrar a 2022, la columna **Tipo** solo contenía valores **Festivo** para días festivos oficiales, pero valores faltantes (NaN) para el resto de días. Se implementó mapeo automático usando **Dia.semana**: lunes-viernes → **laborable**, sábados → **sabado**, domingos → **domingo**.

**Dataset final**: 365 registros con 3 variables: fecha, día de la semana y tipo de día categórico (laborable/sábado/domingo/festivo).

### 2.4.1 Insights Calendario Laboral

El análisis de 2022 revela la distribución del calendario laboral madrileño: aproximadamente 250 días laborables (lunes-viernes no festivos), 52 sábados, 52 domingos, y los días festivos oficiales restantes. Esta categorización proporciona la base fundamental para analizar cómo los patrones de actividad económica y social (días laborables vs fines de semana vs festivos) impactan en los comportamientos de movilidad urbana tanto en BiciMad como en el tráfico vehicular.

## 3 Integración y Análisis Conjunto

Esta sección consolida los cuatro datasets individuales en un análisis unificado que permite examinar las relaciones entre movilidad urbana, condiciones meteorológicas y calendario laboral.

### 3.1 Agregación de Datos

El proceso de integración requirió transformar datasets con diferentes granularidades temporales a un nivel común diario:

**Agregación por día:** Los datos de BiciMad y tráfico, originalmente con granularidad horaria, se agregaron sumando por día. BiciMad se convirtió en número total de viajes diarios, mientras que el tráfico se transformó en afluencia vehicular total diaria. Los datos meteorológicos y de calendario laboral ya estaban en granularidad diaria.

**Fusión mediante inner join:** Se aplicó una estrategia de inner join por fecha para conservar únicamente los días presentes en todos los datasets. Esta aproximación garantizó la integridad temporal pero limitó el análisis a 354 días debido a los 11 días faltantes en el dataset de tráfico (1-11 diciembre 2022).

**Codificación del calendario:** Se creó una variable ordinal `tipo_numerico` donde laborable=0, sábado=1, domingo/festivo=2, reflejando niveles decrecientes de actividad laboral. La distribución final fue: 242 días laborables (68%), 50 sábados (14%) y 62 domingos/festivos (18%).

### 3.2 Análisis de Correlaciones

La matriz de correlaciones de Pearson reveló patrones significativos en la movilidad urbana madrileña:




Figure 1: Heatmap de la matriz de correlaciones



**Impacto del calendario laboral:** El tipo de día mostró correlaciones negativas fuertes tanto con BiciMad (-0.46) como con tráfico vehicular (-0.61). El tráfico presenta mayor sensibilidad al calendario laboral, indicando que los desplazamientos en vehículo privado están más vinculados a actividades laborales que el uso de bicicletas públicas.

**Efectos meteorológicos diferenciados:** La temperatura (tavg) afecta positivamente a BiciMad (+0.38) y negativamente al tráfico (-0.12). La precipitación (prcp) muestra el patrón inverso: negativa para BiciMad (-0.26) y ligeramente positiva para tráfico (+0.14). Esto sugiere que las temperaturas altas favorecen el ciclismo urbano mientras que la lluvia lo desalienta, empujando hacia el transporte vehicular.

**Complementariedad entre modos:** La correlación positiva entre BiciMad y tráfico (+0.46) indica que ambos responden a patrones comunes de demanda de movilidad diaria, funcionando más como complementos que como sustitutos perfectos en el ecosistema de transporte urbano.

Estos resultados confirman que la movilidad urbana está significativamente influenciada tanto por factores estructurales (calendario laboral) como variables (condiciones meteorológicas), con diferentes sensibilidades según el modo de transporte.

## 4 Modelo de datos y creación de métricas en PoweBI




Figure 2: Modelo de Datos Relacional y Tabla de Métricas

## Arquitectura general

El modelo implementa un esquema en estrella con dos niveles de granularidad: diario y horario. Esta estructura permite análisis agregados eficientes (tendencias diarias) y detalle intradiario simultáneamente, unificando bicicletas, tráfico motorizado y contexto meteorológico-temporal

bajo dimensiones comunes.

### Nivel de granularidad diario

- **Tablas centrales:** `Bicimad_Diario` y `Trafico_Diario` (creadas mediante Group By en Power Query a partir de las tablas con los datos a nivel hora).
- **Dimensión:** `DimensionCalendario` con clave `Date`
- **Contexto:** integración con `meteo_madrid_2022_limpio` y `calendario_clean` por fecha
- **Propósito:** visuales de tendencias, comparativas mensuales y análisis de correlaciones clima-movilidad

### Nivel de granularidad horaria

- **Tablas centrales:** `2022_bicimad_cleaned` (nivel viaje) y `trafico_madrid_2022_reestructurado` (nivel estación-hora)
- **Dimensiones:** `DimensionHora` con clave `Hora` (0-23) y `DimensionCalendario` con clave `Date`
- **Propósito:** patrones de uso horario, identificación de horas punta y análisis de estacionalidad diaria

### Relaciones y filtrado

Las tablas de nivel diario se conectan únicamente a `DimensionCalendario`, mientras que las tablas horarias mantienen doble conexión: con `DimensionHora` para análisis intradiario y con `DimensionCalendario` para coherencia temporal por fecha. Esta arquitectura garantiza que los filtros de fecha se propaguen consistentemente a ambos niveles de granularidad, evitando ambigüedades en el análisis cruzado.

### Transformaciones clave

- Agregación diaria en Power Query para optimizar rendimiento en visuales de tendencia
- Creación de tablas auxiliares de ordenación (`OrdenTemp`, `OrdenPrcp`) para categorías meteorológicas
- Tipado consistente de claves temporales (`Date`, `entero`) para relaciones estables

#### 4.0.1 Creación de métricas

Las métricas se organizan en métricas de volumen (totales de tráfico y viajes por día/hora), tendencia central (medias diarias para comparativas temporales) y proporción (ratio bici/tráfico y porcentaje de uso sostenible). Las métricas se centralizan en la tabla “1. Medidas”.

## 5 Resultados e Insights Globales

Este análisis se deriva de los dashboards generados en PowerBI, en donde se puede llegar a una comprensión en mayor profundidad interactuando con los filtros del informe. En esta sección presentamos las principales conclusiones que se derivan del análisis en profundidad del dataset generado.

### 5.1 Magnitudes generales del sistema

El análisis conjunto revela un volumen anual considerable de movilidad urbana: 719.5 millones de registros de tráfico vehicular (media diaria: 2.02 millones) y 4.07 millones de viajes en bicicleta (media diaria: 11.16 mil). Estos datos reflejan un ratio bici/tráfico de 0.57%, indicando el carácter complementario del transporte ciclista frente al motorizado.

### 5.2 Análisis temporal

#### 5.2.1 Variación mensual

##### Tráfico vehicular

- Relativa estabilidad intermensual con pico en marzo (66+ millones)
- Descensos moderados en junio-julio y pronunciado en agosto (47 millones)
- Diciembre presenta valores anómalamente bajos por ausencia de 11 días de registro

##### Uso de bicicletas

- Marcada estacionalidad: máximo en septiembre (447 mil viajes) y mínimo en agosto (270 mil)
- Los meses mayo-septiembre (excepto agosto) concentran el mayor uso ciclista
- Reducción significativa en meses de invierno, coherente con preferencias climáticas

### 5.2.2 Distribución intradiaria

#### Patrones diferenciados por modo de transporte

- **Valle nocturno común:** actividad mínima entre 00:00-07:00 en ambos modos
- **Activación matinal:** incremento abrupto a las 08:00 coincidiendo con inicio laboral
- **Tráfico vehicular:** nivel sostenido desde las 08:00 hasta el final del día
- **Bicicletas:** tres picos diferenciados (08:00, 14:00, 19:00) alineados con horarios laborales (inicio, pausa, finalización)

Esta distribución sugiere que el uso ciclista funciona como transporte complementario orientado a desplazamientos laborales específicos, mientras el tráfico vehicular mantiene demanda constante durante la jornada.

## 5.3 Impacto del tipo de día

### 5.3.1 Diferencias de actividad

La movilidad presenta una clara diferencia según el carácter del día:

- **Laborables:** máxima actividad (bicis: 12.3 mil; vehículos: 2.2M diarios)
- **Sábados, domingos y festivos:** mínima actividad (bicis: 6.8 mil; vehículos: 1.4M)

El diferencial festivo/laborable alcanza el 55% en bicicletas y 63% en tráfico, confirmando la dependencia de ambos modos respecto a la actividad económica.

### 5.3.2 Reconfiguración horaria en no laborables

Los fines de semana y festivos modifican sustancialmente los patrones intradiarios:

- Retraso significativo en el inicio de actividad (de 08:00 a 10:00-12:00)
- Concentración en dos franjas en ambos modos de transporte: 12:00-14:00 y 18:00-20:00
- Desaparición de los tres picos diferenciados del uso ciclista laboral

## 5.4 Influencia meteorológica

### 5.4.1 Temperatura

**Tráfico vehicular:** impacto mínimo en categorías templada, fresca y fría (sobre 2M de media). La reducción en días calurosos (1.87M de media) podría no venir de causalidad, si no de la coincidencia con los meses de verano en los que hay menos actividad, especialmente en agosto.

**Uso ciclista:** preferencia clara por temperaturas templadas (promedio de 13,8 mil viajes), seguidas de las calurosas. Reducción notable en condiciones frescas y especialmente frías, con una media de sólo 8,6 mil viajes al día, coherente con la concentración mayo-septiembre observada mensualmente.

### 5.4.2 Precipitación

Efecto inverso marcado entre modos, como ya había sido detectado en el análisis de correlaciones, donde se observó una correlación negativa (-0.26) entre lluvia y bicicletas, mientras que positiva (0.14) con tráfico:

- Incremento del tráfico vehicular con mayor precipitación
- Descenso proporcional del uso ciclista

## 5.5 Insights de interacción

### 5.5.1 Prevalencia del factor laboral

Los scatter plots por tipo de día y temperatura revelan que **el carácter laboral del día supera en impacto a los factores meteorológicos**. Para todo el rango de temperaturas medias, los días laborables mantienen sistemáticamente mayor actividad que sábados, domingos y festivos, confirmando lo observado en el análisis conjunto previo, donde la correlación observada con la variable tipo\_numerico (-0.46 bicis, -0.61 tráfico) tenía valores absolutos mayores que los asociados a temperatura (0.38 bicis, -0.12 tráfico).

### 5.5.2 Complementariedad modal

La correlación positiva entre bicicletas y tráfico (0.46) indica respuesta común a patrones de movilidad urbana. En todo análisis temporal y con cualquier filtro aplicado, ambas gráficas se

comportan de manera similar, lo que sugiere una complementariedad sistemática entre modos de transporte y confirma la correlación observada en el análisis de correlaciones previo. Sin embargo, los diferentes perfiles intradiarios revelan roles diferenciados: el tráfico como modo base continuo y la bicicleta como complemento para desplazamientos puntuales.

## 6 Conclusiones

El presente estudio ha logrado integrar exitosamente datos de movilidad urbana, meteorología y calendario laboral de Madrid en 2022, generando un análisis comprehensivo de los patrones de transporte sostenible y motorizado en la ciudad.

### 6.1 Logros metodológicos

El proyecto ha demostrado la viabilidad de fusionar fuentes heterogéneas de datos urbanos mediante técnicas de limpieza, normalización y agregación temporal. La arquitectura de datos implementada en Power BI, con doble granularidad (diaria y horaria), permite análisis tanto de tendencias agregadas como de patrones intradiarios detallados.

### 6.2 Hallazgos principales

#### 6.2.1 Factores determinantes de la movilidad

El análisis revela que **el carácter laboral del día constituye el factor más influyente** en ambos modos de transporte, superando en impacto a las condiciones meteorológicas. Los días laborables registran sistemáticamente mayor actividad que fines de semana y festivos, independientemente de las condiciones climáticas.

#### 6.2.2 Complementariedad entre modos de transporte

La correlación positiva (0.46) entre uso de bicicletas y tráfico vehicular, junto con el comportamiento similar observado en todos los análisis temporales, confirma una **complementariedad sistemática** entre ambos modos. Sin embargo, presentan roles diferenciados: el tráfico vehicular mantiene demanda constante durante la jornada, mientras las bicicletas muestran uso concentrado en horarios laborales específicos.

### 6.2.3 Sensibilidad meteorológica diferenciada

Las bicicletas exhiben mayor sensibilidad a condiciones meteorológicas que el tráfico vehicular. La temperatura favorece el uso ciclista (correlación 0.38) y la precipitación lo penaliza (-0.26), mientras el tráfico vehicular muestra menor variabilidad climática.

## 6.3 Implicaciones para políticas de movilidad

Los resultados sugieren oportunidades para políticas de movilidad sostenible:

- **Promoción laboral:** dado el fuerte vínculo entre uso ciclista y actividad laboral, las iniciativas empresariales de movilidad sostenible pueden tener alto impacto.
- **Infraestructura resiliente:** la sensibilidad meteorológica del uso ciclista justifica inversiones en infraestructura protegida (carriles cubiertos, aparcamientos techados).
- **Complementariedad modal:** el comportamiento paralelo de ambos modos sugiere que las políticas de restricción vehicular pueden potenciar efectivamente el uso ciclista si se acompañan de infraestructura adecuada.

## 6.4 Limitaciones y trabajo futuro

El estudio presenta limitaciones que abren líneas de investigación futura. La ausencia de 11 días de datos de tráfico en diciembre afecta la representatividad temporal. La pérdida de granularidad espacial en el análisis conjunto limita insights sobre distribución territorial de la movilidad.

Futuras investigaciones podrían incorporar datos de otros modos de transporte público (metro, bus) para una visión completa del sistema de movilidad, analizar la elasticidad precio-demanda del transporte ciclista mediante datos de tarifas, y desarrollar modelos predictivos de demanda que integren múltiples variables contextuales. También incorporar datos de otras ciudades sería útil a la hora de conseguir una fotografía completa de cómo los factores meteorológicos y de calendario afectan a la movilidad urbana en diferentes contextos geográficos y socioeconómicos.